Un recomendador que entiende el orden: SASRec para videojuegos de Steam

Certamen II · Entrega 1 (avance): Transformer y líneas base · Grupo 6 · Machine Learning, UDD · 03-11-2026
Lucas Hermosilla Díaz · Rodolfo Hidalgo Memmel · Ariel Linero Torres · Docente: Danilo Gómez Correa

1. Rubro, datos y decisión

Rubro: Videojuegos. **Usuario:** Un jugador de Steam que acaba de terminar un juego y busca qué jugar después. **Decisión que apoya la recomendación:** Qué juegos mostrarle en *"Recomendado para ti"*, es decir, su próxima compra. **Base:** Steam Video Game Reviews v2 (UCSD; Kang y McAuley, 2018), la misma del artículo original de SASRec: 7.793.069 reseñas (usuario, juego, fecha) de 2010 a 2018 y metadatos de 32.135 juegos (géneros, etiquetas y precio). En Steam solo reseña quien tiene el juego, así que cada reseña es una señal de compra y uso; la secuencia de un usuario son sus juegos reseñados ordenados por fecha.

2. Hallazgos de la exploración

- **Limpieza y 5-core exigentes.** El 11,6 % de las reseñas eran repetidas (usuario, juego). El 5-core deja 3,5 M de reseñas de 281 mil usuarios y 11.960 juegos. Con una muestra fija de 40.000 usuarios y nuevo 5-core: **482.019 interacciones, 39.401 usuarios y 6.738 juegos**, sobre los mínimos.
- **Muy dispersa y con historiales cortos:** Densidad de 0,18 % y mediana de 8 juegos por usuario; solo el 2,3 % supera los 50 (largo de la ventana).
- **Cola larga marcada:** El 20 % de los juegos concentra el 78,1 % de las reseñas (Team Fortress 2: 4.568; mediana: 18).
- **El orden importa:** Dos juegos consecutivos se parecen en género (Jaccard) un 5,0 % más que con el historial barajado (0,314 vs 0,299), y el parecido cae hasta igualar al azar a distancia 10: lo reciente informa más sobre el próximo juego.
- **Limitación:** La fecha es por día y el 19,2 % de los pares consecutivos comparte fecha; esos empates se ordenan por la línea del archivo original.

3. Decisiones de diseño

- **Datos:** Se conserva la primera reseña de cada par (usuario, juego); el nombre de usuario se reemplaza por un número y no se exporta; los juegos se indexan desde 1 (0 = relleno). El género principal se toma de la etiqueta más votada que sea uno de sus géneros, porque la lista de géneros viene en orden alfabético.
- **Protocolo:** Leave-last-out por usuario (último = prueba, penúltimo = validación), igual para los cuatro modelos. Cada modelo rankea **el catálogo completo** excluyendo lo ya reseñado; no usamos el atajo de 100 negativos al azar del repositorio SASRec.pytorch, que infla las métricas. HR, NDCG y MRR con K = 5, 10, 20 y cobertura@10, verificadas a mano en un usuario (juego oculto en el puesto 2: NDCG = $1/\log_2 3 = 0{,}6309$; MRR = 0,5). Al evaluar en el conjunto de prueba (último ítem), el historial de entrada presentado al modelo corresponde a la secuencia completa hasta el penúltimo juego (entrenamiento + validación), preservando el contexto temporal exacto al momento de la predicción
- **Líneas base** (Entrenamiento): **Popularidad**; Reglas {A} → {B} con **FP-Growth** sobre los 300 juegos más populares, puntaje = mayor lift activado y popularidad como respaldo (soporte mínimo = 0,005, confianza mínima = 0,05 y lift > 1; umbrales fijados a mano, sin ajuste en validación, a diferencia de γ); **ítem–ítem coseno** con peso γ^k para el juego k pasos atrás, con γ = 0,9 elegido en validación (γ = 1 es la bolsa de juegos).
- **SASRec en PyTorch:** Embeddings de juego (× √d) + posición; 1 o 2 bloques con atención causal (máscara triangular que además oculta el relleno), normalización previa, residual y feed-forward; puntaje = producto punto con la misma tabla de embeddings. Entrenamiento estilo GPT sobre trozos de 51 juegos. **Pérdida: entropía cruzada sobre todo el catálogo** (la del handout y la de un modelo de lenguaje): coincide con la evaluación por ranking completo, con 6.738 juegos es

barata en GPU y evita muestrear negativos, a diferencia de la BCE con un negativo del repositorio original.

- **Selección:** Tres configuraciones (A: d = 64, 1 bloque; B: d = 64, 2 bloques y 2 cabezas; C: d = 128, 2 bloques, dropout 0,3), Adam 0,001, parada temprana con 5 épocas sin mejorar el NDCG@10 de validación. Semilla 2026 en muestra, partición y PyTorch; la prueba se evaluó una sola vez.

4. Resultados

Modelo	HR@5	HR@10	HR@20	NDCG@5	NDCG@10	NDCG@20	MRR@10	MRR@20	Cobertura
Popularidad	0,0363	0,0552	0,0827	0,0221	0,0282	0,0350	0,0200	0,0218	0,9 %
Reglas de asociación	0,0367	0,0572	0,0865	0,0223	0,0288	0,0362	0,0203	0,0222	0,9 %
Coseno (γ = 0,9)	0,0526	0,0861	0,1330	0,0345	0,0452	0,0570	0,0329	0,0361	75,6 %
SASRec (config C)	**0,0690**	**0,1110**	**0,1698**	**0,0446**	**0,0580**	**0,0728**	**0,0421**	**0,0461**	**56,5 %**

Tabla 1. Métricas en prueba (39.401 usuarios, ranking de 6.738 juegos; cobertura con Top-10). SASRec gana en todas las métricas de precisión.

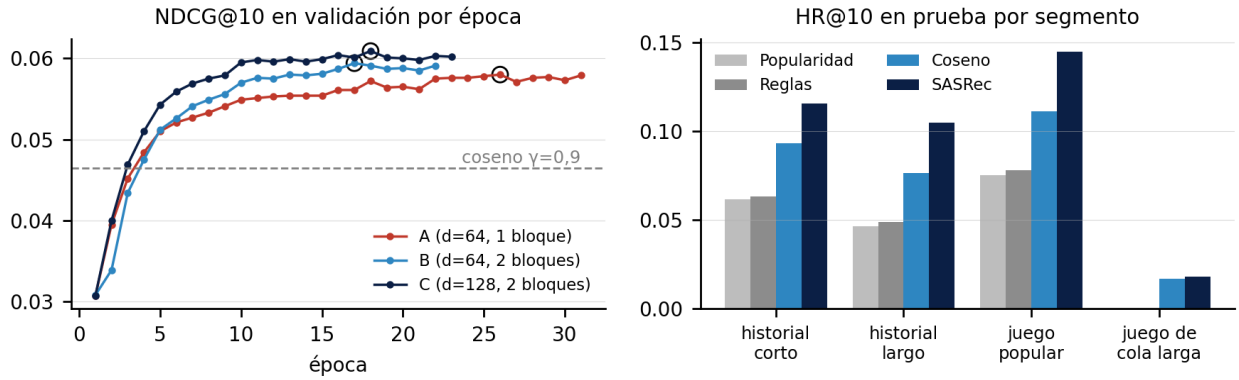


Figura 1. Izquierda: curvas de validación de las tres configuraciones (círculo = época elegida). Derecha: HR@10 en prueba por segmento.

- **Precisión:** SASRec acierta el próximo juego en el Top-10 del 11,1 % de los usuarios, **+29 %** sobre la mejor línea base (coseno), con mejoras similares en NDCG@10 (+28 %) y MRR@20 (+28 %). Las reglas apenas superan a la popularidad: solo hay 252 reglas, porque en una base tan dispersa pocos pares alcanzan soporte, y sus umbrales no se ajustaron en validación.
- **Selección:** Las tres configuraciones quedaron cerca (NDCG@10 de validación 0,058, 0,059 y 0,061); ganó la C, que se detuvo en la época 23 con el mejor estado en la 18. Todas superan al coseno desde la época 4.
- **Segmentos:** La ventaja sobre el coseno es mayor en historiales largos (+37 %) que en cortos (+24 %), coherente con que la atención aprovecha la secuencia. En los juegos de cola larga todos fallan (HR@10 ≤ 0,018): sigue siendo el problema abierto.
- **Cobertura:** SASRec recomienda el 56,5 % del catálogo frente al 0,9 % de popularidad, pero menos que el coseno (75,6 %): cambia algo de diversidad por precisión.
- **Interpretabilidad:** En el notebook se analizan tres usuarios representativos con historiales de distinto largo (corto, medio y largo), evidenciando cómo los pesos de atención concentran mayor peso en los títulos más recientes y en la coherencia temática del Top-5. Los pesos que se grafican son los del último bloque Transformer, promediando sus 2 cabezas de atención (average_attn_weights=True), por lo que muestran el foco conjunto y no el de cada cabeza. En un usuario que venía de *Rainbow Six Siege*, *Squad* e *Insurgency*, todo el Top-5 fue de disparos y acertó *Call of Duty: WWII* en el puesto 2. Sin ver nunca los géneros, los embeddings de juegos del mismo género quedaron más cerca (coseno promedio 0,028 vs −0,003).

5. Costo-beneficio

Modelo	Tamaño	Entrenamiento	Inferencia (ms/usuario)	NDCG@10
Popularidad	6.738 conteos	≈ 0 s	0,046	0,0282
Reglas de asociación	252 reglas	16 s	0,070	0,0288
Ítem–ítem coseno	45,4 M similitudes	1 s	0,080	0,0452
SASRec (config C)	**1,07 M pesos (4,3 MB)**	**262 s (724 s las tres)**	**0,093**	**0,0580**

Tabla 2. Costo en GPU T4 de Colab.

SASRec es el más caro de entrenar, pero el costo se paga una vez y son minutos. En inferencia cuesta casi lo mismo que las líneas base (menos de 0,1 ms por usuario) y el modelo pesa 4,3 MB: comprobamos que cargado en CPU entrega las mismas recomendaciones, así que el dashboard puede usarlo sin GPU. Incluso es más compacto que el coseno, que guarda una matriz de 45 millones de similitudes.

¿Vale la pena el Transformer en videojuegos?

Sí. El orden de los historiales tiene señal (hallazgo 4) y SASRec la aprovecha: casi un 30 % más de aciertos por unos minutos de entrenamiento. **Límites:** La fecha es por día, la reseña es una señal imperfecta de compra, trabajamos con una muestra de 40.000 usuarios, la cola larga sigue sin resolverse y predecir el siguiente juego no explica por qué la persona lo eligió. Nuestros valores no son comparables con el HR@10 ≈ 0,87 del artículo original, que compara contra solo 100 juegos al azar.

6. Plan para la Entrega 2

- **Dashboard en Streamlit** ambientado como tienda de juegos y publicado desde GitHub: catálogo y populares, simulador de historial en orden con el Top-N de SASRec y de la mejor línea base, pesos de atención, tabla de métricas. Carga **sasrec.pt** en CPU con caché; nada se entrena en la app.
- **Analista con LLM:** Recibe el historial con géneros y precio, el Top-N con puntajes, los pesos de atención, el Top-N del coseno y la popularidad; solo comenta esos juegos, sin agregar ni reordenar. Si la pregunta exige otra lista, se vuelve a consultar al modelo. Instrucciones en **src/analista_prompt.md**, cinco pruebas de honestidad, costo en tokens y latencia, y clave en **st.secrets**.
- **Innovación (por inscribir):** Un auditor de sesgo de popularidad que mida novedad y diversidad de cada lista, motivado por la baja cobertura frente al coseno y el mal desempeño en cola larga hallados aquí.